

# Iterative Closest Point (ICP) 匹配算法

## 算法功能简介

- ICP (Iterative Closest Point, 迭代最近点) 算法是一种点集-点集的匹配方法，基于最小二乘法，计算一个匹配变换以使得点集与点集尽量重叠。
- ICP算法的输入为两帧待匹配的点云，数据格式为[x, y, z]，即点云的三维坐标。
- 重要的接口函数：

- 【输入】 `void pcl::IterativeClosestPoint::setInputCloud(const PointCloudSourceConstPtr& cloud)`


设置源点云（被变换以进行匹配的点云），在匹配过程中不断迭代变换位置。需要的数据格式为[x, y, z]，即点云的三维坐标。

- 【输入】 `void pcl::IterativeClosestPoint::setInputTarget(const PointCloudTargetConstPtr& cloud)`

设置目标点云（通常是地图点云），在匹配过程中保持不变。需要的数据格式为[x, y, z]，即点云的三维坐标。

- 【输出】 `void pcl::IterativeClosestPoint::align(PointCloudSource& output)`

进行ICP匹配，参数返回匹配后的源点云。产生的数据格式为[x, y, z]，即点云的三维坐标。



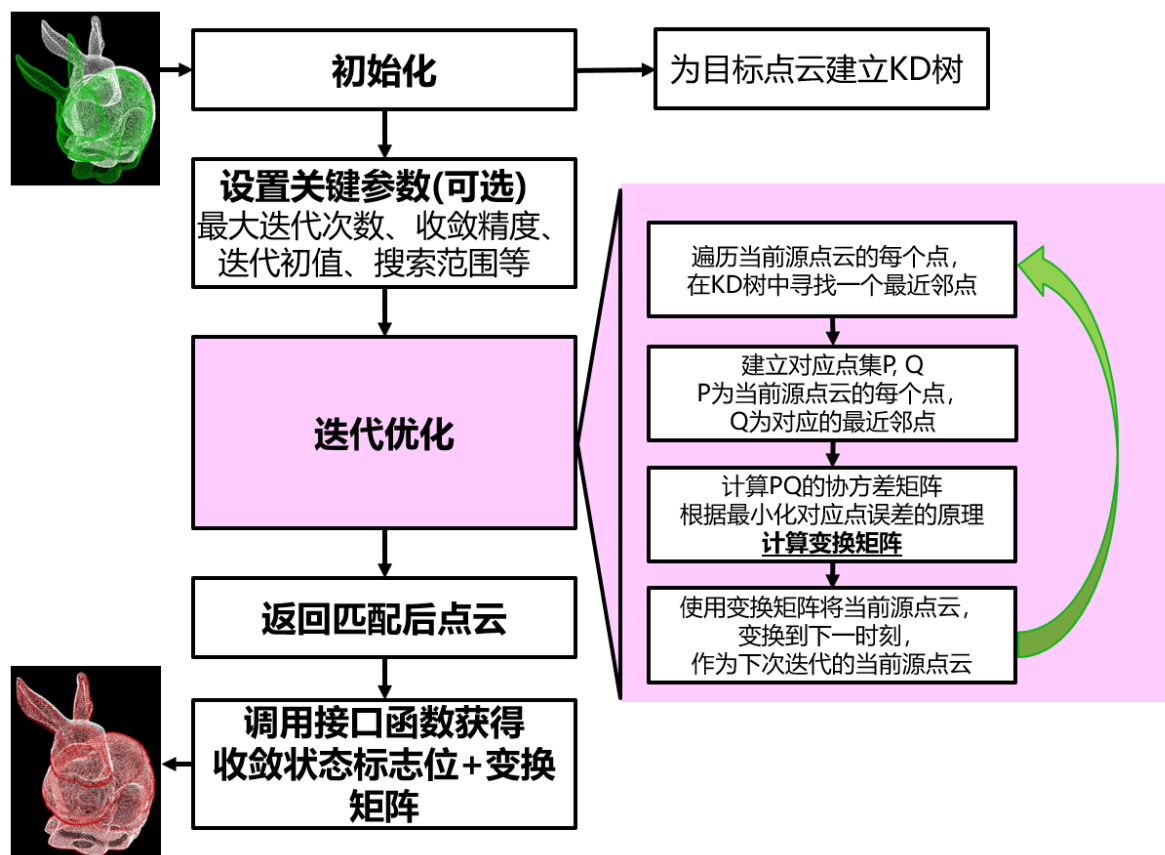
- 【可选输入】 `void setMaximumIterations(int nr_iterations)`  
设置最大迭代次数。
- 【可选输入】 `void setMaxCorrespondenceDistance(double distance_threshold)`  
设置搜寻最近点时的搜寻范围半径。
- 【可选输入】 `void setTransformationEpsilon(double epsilon)`  
设置判断收敛的迭代步长阈值。
- 【可选输入】 `void setEuclideanFitnessEpsilon(double epsilon)`  
设置判断收敛的误差精度阈值。
- 【可选输出】 `double getFitnessScore(double max_range = std::numeric_limits<double>::max());`

函数返回两帧点云匹配的均方误差值。

- 【可选输出】 `Matrix4 getFinalTransformation()`

函数返回两帧点云匹配使用的4\*4变换矩阵。

## 算法计算流程



todo: KD树的建立算法流程。

其中，计算变换矩阵的具体数学推导过程如下。

关于矩阵求解数学推导: <https://zhuanlan.zhihu.com/p/107218828>

两组对应的点集:

$$P = \{p_1, p_2, \dots, p_n\}$$
$$Q = \{q_1, q_2, \dots, q_n\}$$

求欧式变换  $R, t$  使得:

$$\forall i, \quad q_i = Rp_i + t$$

ICP 算法基于最小二乘法进行迭代计算，使得误差平方和达到极小值:

$$\operatorname{argmin}_{R, t} \sum_{i=1}^n \|(Rp_i + t) - q_i\|^2$$

(1) 求解 translation

$$F(t) = \sum_{i=1}^n \|(Rp_i + t) - q_i\|^2$$

$F(\mathbf{t})$  对  $\mathbf{t}$  求偏导, 可得:

$$\frac{\partial F}{\partial \mathbf{t}} = \sum_{i=1}^n 2(R\mathbf{p}_i + \mathbf{t} - \mathbf{q}_i) = 2R \sum_{i=1}^n \mathbf{p}_i + 2\mathbf{t} \cdot n - 2 \sum_{i=1}^n \mathbf{q}_i$$

令  $\frac{\partial F}{\partial \mathbf{t}} = \mathbf{0}$ , 求得:

$$\mathbf{t} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}_i - R \frac{1}{n} \sum_{i=1}^n \mathbf{p}_i$$

定义质心:

$$\bar{\mathbf{p}} = \frac{1}{n} \sum_{i=1}^n \mathbf{p}_i$$

$$\bar{\mathbf{q}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}_i$$

因而,

$$\mathbf{t} = \bar{\mathbf{q}} - R\bar{\mathbf{p}}$$

将  $\mathbf{t}$  代入  $F(\mathbf{t})$  可得:

$$\begin{aligned} \sum_{i=1}^n \|(R\mathbf{p}_i + \mathbf{t}) - \mathbf{q}_i\|^2 &= \sum_{i=1}^n \|R\mathbf{p}_i + \bar{\mathbf{q}} - R\bar{\mathbf{p}} - \mathbf{q}_i\|^2 \\ &= \sum_{i=1}^n \|R(\mathbf{p}_i - \bar{\mathbf{p}}) - (\mathbf{q}_i - \bar{\mathbf{q}})\|^2 \end{aligned}$$

定义去质心坐标:

$$\mathbf{x}_i = \mathbf{p}_i - \bar{\mathbf{p}}$$

$$\mathbf{y}_i = \mathbf{q}_i - \bar{\mathbf{q}}$$

因此, 目标函数变为:

$$\operatorname{argmin}_R \sum_{i=1}^n \|R\mathbf{x}_i - \mathbf{y}_i\|^2$$

(2) 求解 rotation

$$\begin{aligned} \|R\mathbf{x}_i - \mathbf{y}_i\|^2 &= (R\mathbf{x}_i - \mathbf{y}_i)^\top (R\mathbf{x}_i - \mathbf{y}_i) \\ &= (\mathbf{x}_i^\top R^\top - \mathbf{y}_i^\top) (R\mathbf{x}_i - \mathbf{y}_i) \\ &= \mathbf{x}_i^\top R^\top R\mathbf{x}_i - \mathbf{y}_i^\top R\mathbf{x}_i - \mathbf{x}_i^\top R^\top \mathbf{y}_i + \mathbf{y}_i^\top \mathbf{y}_i \\ &= \mathbf{x}_i^\top \mathbf{x}_i - \mathbf{y}_i^\top R\mathbf{x}_i - \mathbf{x}_i^\top R^\top \mathbf{y}_i + \mathbf{y}_i^\top \mathbf{y}_i \end{aligned}$$

$\mathbf{x}_i^\top R^\top \mathbf{y}_i$  是标量, 对于任意标量  $a$ , 都满足  $a = a^T$ , 因此,

$$\mathbf{x}_i^\top R^\top \mathbf{y}_i = (\mathbf{x}_i^\top R^\top \mathbf{y}_i)^\top = \mathbf{y}_i^\top R \mathbf{x}_i$$

$$\|R\mathbf{x}_i - \mathbf{y}_i\|^2 = \mathbf{x}_i^\top \mathbf{x}_i - 2\mathbf{y}_i^\top R\mathbf{x}_i + \mathbf{y}_i^\top \mathbf{y}_i$$

将其代入目标函数，可得：

$$\begin{aligned} \operatorname{argmin}_R \sum_{i=1}^n \|R\mathbf{x}_i - \mathbf{y}_i\|^2 &= \operatorname{argmin}_R \sum_{i=1}^n (\mathbf{x}_i^\top \mathbf{x}_i - 2\mathbf{y}_i^\top R\mathbf{x}_i + \mathbf{y}_i^\top \mathbf{y}_i) \\ &= \operatorname{argmin}_R \left( \sum_{i=1}^n \mathbf{x}_i^\top \mathbf{x}_i - 2 \sum_{i=1}^n \mathbf{y}_i^\top R\mathbf{x}_i + \sum_{i=1}^n \mathbf{y}_i^\top \mathbf{y}_i \right) \\ &= \operatorname{argmin}_R \left( -2 \sum_{i=1}^n \mathbf{y}_i^\top R\mathbf{x}_i \right) \end{aligned}$$

因而，

$$\operatorname{argmin}_R \left( -2 \sum_{i=1}^n \mathbf{y}_i^\top R\mathbf{x}_i \right) = \operatorname{argmax}_R \sum_{i=1}^n \mathbf{y}_i^\top R\mathbf{x}_i$$

$$\begin{aligned} & \begin{bmatrix} -\mathbf{y}_1^\top & - \\ -\mathbf{y}_2^\top & - \\ \vdots & \\ -\mathbf{y}_n^\top & - \end{bmatrix} \begin{bmatrix} R \end{bmatrix} \begin{bmatrix} | & | & \dots & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \dots & \mathbf{x}_n \\ | & | & & | \end{bmatrix} = \\ &= \begin{bmatrix} - & \mathbf{y}_1^\top & - \\ - & \mathbf{y}_2^\top & - \\ & \vdots & \\ - & \mathbf{y}_n^\top & - \end{bmatrix} \begin{bmatrix} | & | & \dots & | \\ R\mathbf{x}_1 & R\mathbf{x}_2 & \dots & R\mathbf{x}_n \\ | & | & & | \end{bmatrix} = \begin{bmatrix} \mathbf{y}_1^\top R\mathbf{x}_1 & & & * \\ & \mathbf{y}_2^\top R\mathbf{x}_2 & & \\ & & \ddots & \\ * & & & \mathbf{y}_n^\top R\mathbf{x}_n \end{bmatrix} \end{aligned}$$

由上图可知，

$$\sum_{i=1}^n \mathbf{y}_i^\top R\mathbf{x}_i = \operatorname{tr}(\mathbf{Y}^\top R\mathbf{X}) = \operatorname{tr}(R\mathbf{X}\mathbf{Y}^\top)$$

其中， $\mathbf{X}$  和  $\mathbf{Y}$  为  $3 \times n$  维矩阵。

定义协方差矩阵  $\mathbf{S} = \mathbf{X}\mathbf{Y}^\top$ ，对  $\mathbf{S}$  做 SVD 分解：

$$\mathbf{S} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$$

因而，求解问题变为使下式最大化：

$$\operatorname{tr}(\mathbf{R}\mathbf{X}\mathbf{Y}^\top) = \operatorname{tr}(\mathbf{R}\mathbf{S}) = \operatorname{tr}(\mathbf{R}\mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top) = \operatorname{tr}(\mathbf{\Sigma}\mathbf{V}^\top \mathbf{R}\mathbf{U})$$

令  $\mathbf{M} = \mathbf{V}^\top \mathbf{R}\mathbf{U}$ ，由于满足  $\mathbf{M}\mathbf{M}^\top = \mathbf{E}$ ，故  $\mathbf{M}$  是正交阵，其列向量  $\mathbf{m}_j$  是 orthonormal vectors，即  $\mathbf{m}_j^\top \mathbf{m}_j = 1$ 。因此，对  $\mathbf{M}$  的所有元素都有  $m_{ij} \leq 1$ 。

$$\text{tr}(\Sigma M) = \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_d \end{pmatrix} \begin{pmatrix} m_{11} & m_{12} & \dots & m_{1d} \\ m_{21} & m_{22} & \dots & m_{2d} \\ \vdots & \vdots & \vdots & \vdots \\ m_{d1} & m_{d2} & \dots & m_{dd} \end{pmatrix} = \sum_{i=1}^d \sigma_i m_{ii} \leq \sum_{i=1}^d \sigma_i$$

当  $m_{ii} = 1$  时,  $\text{tr}(\Sigma M)$  最大;  $M$  又是正交阵, 因此  $M$  必为单位阵。

$$I = M = V^T R U \Rightarrow R = V U^T$$

### (3) SVD计算方法

$$S = U \Sigma V^T$$

1. 计算  $SS^T$  和  $S^T S$ ;
2. 分别计算  $SS^T$  和  $S^T S$  的特征向量及其特征值;
3.  $SS^T$  的特征向量组成  $U$ ; 而  $S^T S$  的特征向量组成  $V$ ;
4. 对  $SS^T$  和  $S^T S$  的非零特征值求平方根, 对应上述特征向量的位置, 填入  $\Sigma$  的对角元。

## 样例效果展示

白色代表目标点云 (通常为地图点云)。

红色代表本次迭代前的源点云, 绿线代表源点云及其在目标点云中找到的对应点。

蓝色代表本次迭代后的源点云, 作为下次迭代前的输入。

